IA RH : Prédiction du Turnover et Aide à la Rétention

Transformer une RH réactive en RH prédictive—parce que chaque départ crée un coût caché en recrutement, onboarding et perte de savoir.

Problématique Métier : Pourquoi nos talents partent-ils ?

L'enjeu financier

Chaque départ représente un coût de remplacement estimé à **6 à 9 mois de salaire** — entre recrutement, formation et montée en compétences.

Les signaux ignorés

Les absences répétées, la baisse d'engagement et les frictions managériales précèdent souvent la démission de plusieurs mois. Ces signaux faibles restent trop souvent invisibles faute d'outils adaptés.

- Surcharge des équipes restantes
- Perte de continuité et de savoir métier
- Besoin : détecter les risques **avant** la démission

Vision : de RH Pompier à RH Prédictive

Avant

On réagit **après** les départs. L'entretien de sortie arrive trop tard. Les équipes subissent les conséquences sans avoir pu anticiper.

Après

On anticipe les **profils à risque** grâce au score IA. Les entretiens de rétention sont priorisés, les décisions RH appuyées par des explications claires et actionnables.

L'objectif n'est pas de remplacer le jugement humain, mais de l'outiller avec des données fiables pour agir au bon moment.

Analyse des Données (EDA)

Dataset `HRDataset_v14.csv` — **311 employés, 36 variables**. Cible : `Termd` (0 = reste, 1 = départ). Taux de départ global : **33,4 %**.

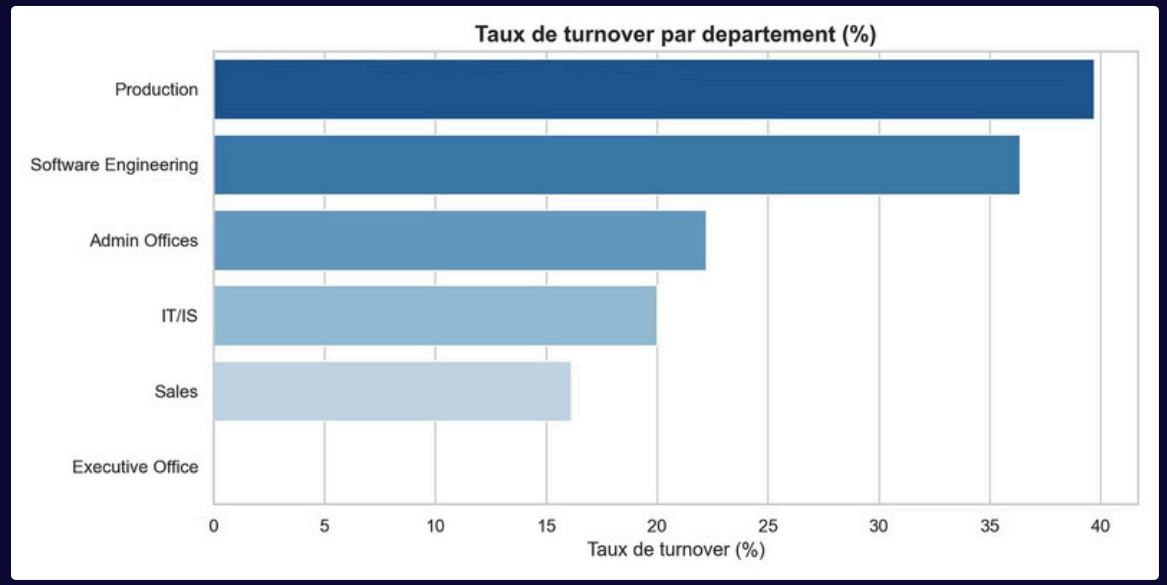

Principaux signaux détectés

- **Production** concentre le plus de départs (83 cas, ~40 % du département)
- Absences moyennes plus élevées chez les sortants : **11,05 vs 9,83 jours/an**
- La satisfaction seule discrimine peu — d'autres facteurs sont déterminants

Pipeline de Traitement et Reproductibilité

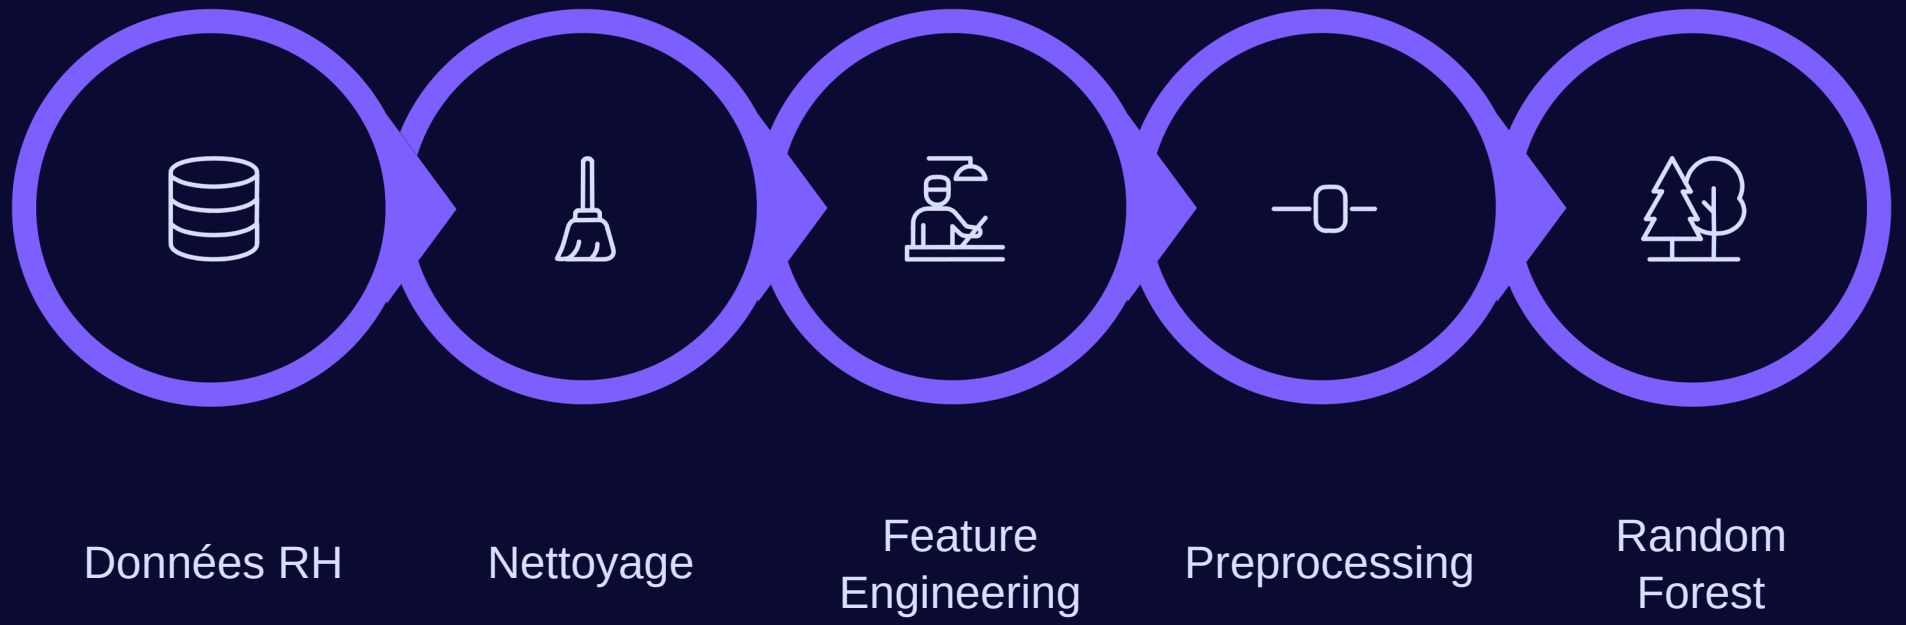

Le pipeline garantit une reproductibilité totale : split stratifié (`test_size=0.25`, `random_state=42`), variables construites (TenureYears, EngagementCombined, AbsencesPerYear, SalaryBand) et suppression systématique des colonnes à fuite d'information.

Approche de Modélisation

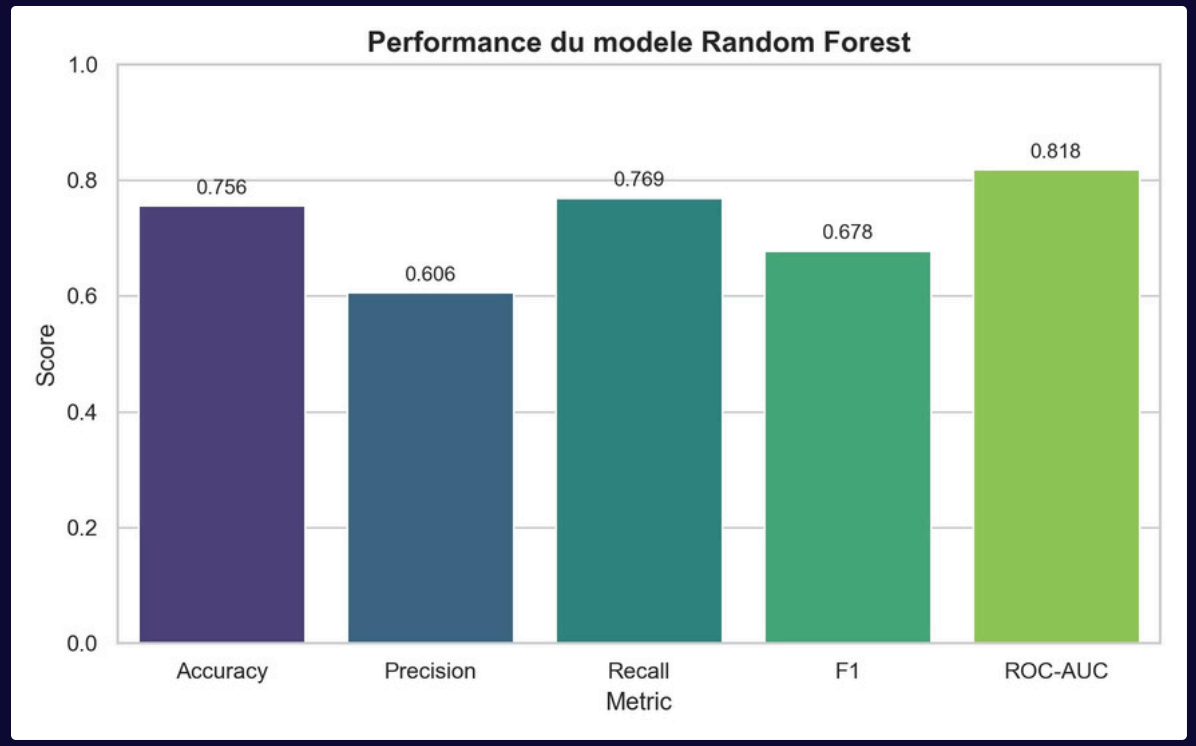

10 modèles comparés

Régression logistique, Random Forest, SVM, Gradient Boosting, KNN, et autres. Le **RandomForestClassifier** se distingue avec le meilleur équilibre performance / interprétabilité.

- Sortie : **score de risque** entre 0 et 1
- Variables sensibles exclues : sexe, origine, ethnicité
- Traduction métier via LLM : score + facteurs → recommandations RH

Résultats et Insights

81.8%

Excellente capacité discriminante du modèle

76.9%

Profils à risque bien détectés — priorité prévention

75.6%

Fiabilité globale sur l'ensemble de test

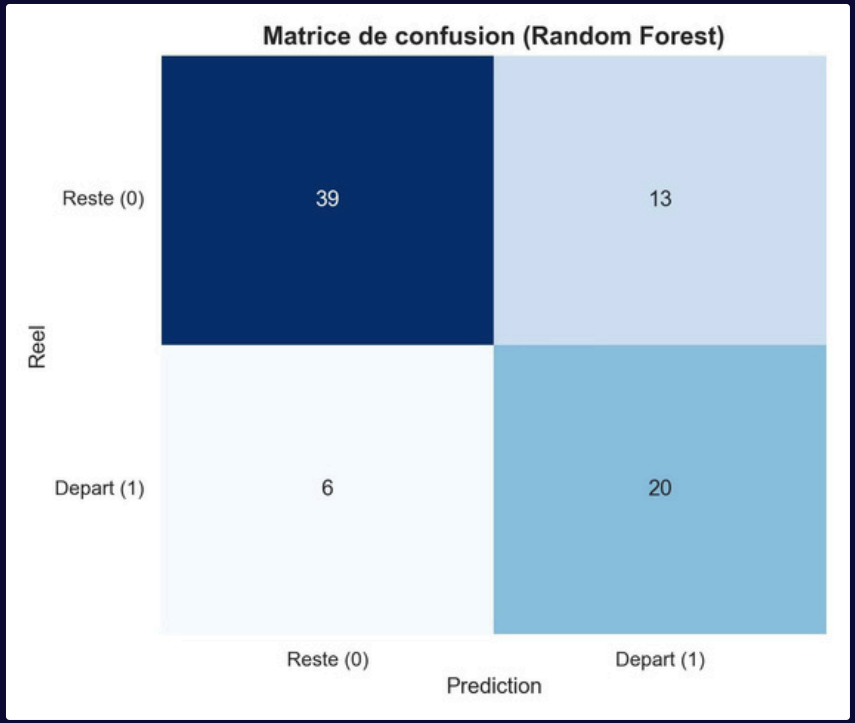

Drivers principaux du départ

- **TenureYears** — ancienneté dans l'entreprise
- **Position & Département** — contexte de travail
- **EngagementCombined** — engagement agrégé
- **Salary** — niveau de rémunération

Un recall élevé est privilégié : mieux vaut identifier trop de profils à risque que d'en manquer.

IA Générative (Grok API)

Transformer les prédictions en recommandations RH

1

Intégration d'un LLM via Grok API

Nous utilisons l'API Grok pour intégrer un modèle de langage

2

Explicabilité et Transparence

Le **LLM** explique **pourquoi** un employé est à risque : quels facteurs influencent le score, dans quel ordre, avec quel poids

3

Assistant d'aide à la décision

Le **LLM** agit comme un assistant, pas comme un décideur automatique

4

Recommandations Actionnables

Le **LLM** propose des **actions concrètes** : entretien de rétention, ajustement de salaire, changement de poste, etc.

Grok

Sécurité et Conformité

Prompts encadrés

Aucune affirmation certaine.Variables sensibles (sexe, origine) **exclues** des entrées du modèle et des prompts LLM.

Protection des secrets

Clés API stockées en variables d'environnement (`.env`).

Journalisation sécurisée sans données personnelles ni secrets.

Robustesse des entrées

Validation de type et plage pour `employee_id`. Filtrage des entrées invalides et des tentatives d'injection. Construction de prompt depuis champs structurés fiables uniquement.

Robustesse et Pratiques d'Ingénierie

Architecture modulaire

Notre code est organisé comme un jeu de construction : nous utilisons des briques indépendantes, chacune ayant une mission précise. Au lieu d'un bloc unique et complexe, nous avons séparé les responsabilités pour que chaque élément fonctionne de manière autonome tout en s'assemblant parfaitement.

Pourquoi est-ce important ?

- **Facile à maintenir :** Si une brique pose problème, nous savons exactement où intervenir.
- **Facile à tester :** Nous pouvons vérifier chaque pièce séparément pour garantir sa fiabilité.
- **Facile à améliorer :** Nous pouvons faire évoluer une partie sans risquer de casser le reste.
- **Prêt à grandir :** Nous pouvons ajouter de nouvelles fonctionnalités sereinement.

Predictor Client
Fait les prédictions

Prompt Builder
Prépare les questions pour l'IA

LLM Client
Appelle l'IA pour les explications

Explanation Generator
Traduit les résultats en langage RH

Cette organisation permet d'évoluer progressivement : d'abord un script, puis une API, puis un dashboard — sans tout recommencer.

Conclusion et Feuille de Route

1

Valeur Métier

Prioriser les actions de rétention avant la démission. IA responsable : variables sensibles exclues.

2

Valeur Technique

Pipeline reproductible, benchmark de 10 modèles, explicabilité LLM intégrée.

3

Prochaines Étapes

Sécurisation des clés, dashboard RH, audit fairness, API, monitoring de drift et ré-entraînement périodique.